Multiplicación de matrices de forma secuencial y paralela

Caso de Estudio 1 — Computación de Alto Rendimiento

Daniel Toro Soto , Juan Camilo Galvis

Marzo 2026

Resumen

El presente documento describe el proceso de implementación y análisis comparativo del algoritmo de multiplicación de matrices cuadradas en el lenguaje C, evaluado bajo cuatro estrategias de ejecución: secuencial ingenuo, secuencial con optimizaciones del compilador (`-O2`), secuencial con optimización de caché (transposición de matrices) y paralela mediante hilos POSIX (`pthread`) y procesos (`fork`). Las pruebas se realizaron sobre matrices cuadradas de dimensiones entre 500 y 4000, con 10 repeticiones por configuración, variando el número de trabajadores (2, 4, 8 y 16) para las versiones paralelas. Los resultados se obtuvieron sobre un Apple Mac Mini con procesador M4 de 10 núcleos y 16 GB de memoria unificada. Se analizan tiempos de ejecución, speedup y el impacto de la localidad de caché, obteniendo conclusiones sobre la eficiencia real del paralelismo en hardware Apple Silicon.

Índice

1. Introducción **3**

2. Marco Conceptual **3**
2.1. High Performance Computing (HPC) . . . 3
2.2. Multiplicación matricial . . . 3
2.3. Complejidad Computacional y localidad de caché . . . 3
2.4. Programación paralela . . . 3
2.5. Hilos vs. Procesos . . . 4
2.6. Speedup . . . 4

3. Marco Contextual **4**
3.1. Características de la máquina . . . 4
3.2. Desarrollo . . . 4
3.3. Sistema de compilación (Makefile) . . . 5
3.4. Sistema de benchmarking con checkpoints . . . 5
3.5. Problema de medición: CPU acumulado vs. tiempo de pared . . . 6

4. Pruebas **6**
4.1. Secuencial . . . 6
4.2. Secuencial con flag . . . 7
4.3. Optimización de caché (Transpuesta) . . . 7
4.4. Multiprocesamiento — 2 Procesos . . . 7
4.5. Multiprocesamiento — 4 Procesos . . . 7
4.6. Multiprocesamiento — 8 Procesos . . . 8
4.7. Multiprocesamiento — 16 Procesos . . . 8
4.8. Hilos POSIX — 2 Hilos . . . 8
4.9. Hilos POSIX — 4 Hilos . . . 8
4.10. Hilos POSIX — 8 Hilos . . . 9
4.11. Hilos POSIX — 16 Hilos . . . 9

5. Gráficas comparativas **9**

6. Análisis de resultados **12**
6.1. Impacto del compilador (`-O2`) 12
6.2. Optimización de caché (transpuesta) 12
6.3. Paralelismo con hilos 12
6.4. Paralelismo con procesos 13

7. Conclusiones **13**

8. Bibliografía **14**

1. Introducción

A lo largo de los años la computación ha evolucionado hasta el punto de poder resolver problemas de grandes dimensiones en tiempos cada vez más reducidos. La multiplicación de matrices es uno de los problemas de referencia en esta área: a pesar de su sencillez conceptual, su complejidad $\mathcal{O}(n^3)$ lo convierte en un candidato ideal para evaluar estrategias de paralelización y optimización.

Como señalan Qaz Wiki (2020), "se ha invertido mucho trabajo en hacer que los algoritmos de multiplicación de matrices sean eficientes [...] Se han diseñado muchos algoritmos diferentes para multiplicar matrices en diferentes tipos de hardware, incluidos sistemas paralelos y distribuidos, donde el trabajo computacional se distribuye en múltiples procesadores". En este estudio se implementaron cinco variantes del algoritmo en C: una versión base secuencial, la misma versión compilada con la bandera de optimización `-O2`, una versión que explota la localidad de caché transponiendo la segunda matriz, y versiones paralelas con hilos y procesos.

Con base en el concepto de *speedup* —la razón entre el tiempo secuencial y el tiempo paralelo— se busca cuantificar la ganancia real obtenida al paralelizar, considerando el efecto de la arquitectura Apple M4 (núcleos heterogéneos de rendimiento y eficiencia) y el papel del subsistema de memoria unificada de alta velocidad de esta plataforma.

Finalmente, el estudio busca determinar a partir de qué dimensión de matriz el paralelismo compensa su overhead y cuántos trabajadores resultan óptimos en esta arquitectura particular.

2. Marco Conceptual

2.1. High Performance Computing (HPC)

Cuando hablamos de HPC, "hacemos referencia a un campo de la computación actual que da solución a problemas tecnológicos muy complejos y que involucran un gran volumen de cálculos o de coste computacional" (López, 2017). En este caso de estudio, el aumento de la dimensión de las matrices implica un crecimiento cúbico del trabajo computacional, lo que justifica el uso de técnicas de HPC como la paralelización y la optimización de accesos a memoria.

2.2. Multiplicación matricial

Dadas dos matrices cuadradas A y B de dimensión n:

$$A := (a_{ij})_{n\times n} \qquad B := (b_{ij})_{n\times n}$$

El producto $C = AB$ genera una matriz resultado $C := (c_{ij})_{n\times n}$ donde:

$$c_{ij} = \sum_{k=1}^{n} a_{ik} \cdot b_{kj}$$

Esta definición expone directamente los tres bucles anidados del algoritmo ingenuo, con complejidad temporal $\mathcal{O}(n^3)$ y complejidad espacial $\mathcal{O}(n^2)$.

2.3. Complejidad Computacional y localidad de caché

La Teoría de la Complejidad estudia la eficiencia de los algoritmos en función de los recursos que utiliza (Cortéz, 2004). Para matrices de gran dimensión, el patrón de acceso a memoria es crítico: el algoritmo ingenuo accede a la columna j de B iterando sobre k, lo que produce fallos de caché continuos al no respetar la disposición en fila mayor (*row-major*) del lenguaje C. Transponer B antes de multiplicar convierte esos accesos en secuenciales, mejorando significativamente el rendimiento para matrices grandes.

2.4. Programación paralela

"La computación paralela es el uso de múltiples recursos computacionales para resolver un problema. Se distingue de la computación secuencial en que varias operaciones pueden ocurrir simultáneamente" (Ferestrepoca, 2019). En este estudio se emplean dos mecanismos de paralelismo:

- **Hilos POSIX (`pthread`)**: comparten el espacio de memoria del proceso, con bajo overhead de creación y comunicación.

- **Procesos (`fork`)**: cada proceso tiene su propio espacio de memoria; la matriz resultado se comparte mediante `mmap(MAP_SHARED | MAP_ANONYMOUS)`.

2.5. Hilos vs. Procesos

"La diferencia fundamental entre hilos y procesos es que un proceso dispone de un espacio de memoria separado, mientras que un hilo no. De esta forma los hilos pueden trabajar directamente con las variables creadas por el proceso padre, mientras que los procesos hijos no pueden hacerlo" (Montero & Antunez, 2011). Esta diferencia se refleja en el overhead de cada enfoque y, en consecuencia, en su speedup efectivo.

2.6. Speedup

El speedup representa la ganancia en rendimiento de la versión paralela respecto a la secuencial:

$$S_p = \frac{T^*(n)}{T_p(n)}$$

donde $T^*(n)$ es el tiempo de ejecución secuencial y $T_p(n)$ el tiempo con p trabajadores. El speedup ideal es lineal ($S_p = p$), pero en la práctica se ve limitado por porciones secuenciales (Ley de Amdahl [7]) y por el overhead de sincronización.

3. Marco Contextual

3.1. Características de la máquina

Las pruebas se realizaron sobre el siguiente hardware:

- **Equipo:** Apple Mac Mini (2024)
- **Procesador:** Apple M4 — 10 núcleos (4 de rendimiento + 6 de eficiencia)
- **GPU integrada:** 10 núcleos
- **Memoria:** 16 GB RAM unificada LPDDR5X (banda ancha ≈120 GB/s) [6]
- **Almacenamiento:** 512 GB SSD NVMe
- **Sistema operativo:** macOS Sequoia 15.x (Darwin 25.x)
- **Compilador:** Apple Clang 16 (LLVM)

La arquitectura Apple M4 presenta características relevantes para este estudio: la memoria unificada elimina la transferencia entre CPU y memoria separada, y los núcleos heterogéneos (P-cores y E-cores) implican que el speedup al pasar de 8 a 16 trabajadores puede verse afectado por la diferencia de rendimiento entre tipos de núcleo.

Las pruebas evaluaron matrices cuadradas de dimensiones: **500, 1000, 1300, 1600, 2000, 2300, 2600, 3000, 3300, 3600 y 4000**, con **10 repeticiones** por configuración para obtener promedios estadísticamente representativos.

3.2. Desarrollo

Las cinco implementaciones en C comparten la misma estructura base: generación aleatoria de matrices con enteros entre 0 y 99 (librería `stdlib.h`), multiplicación y medición del tiempo de CPU mediante `getrusage(RUSAGE_SELF, ...)` con `ru_utime`. El tiempo impreso en stdout corresponde al tiempo de usuario en segundos con 6 decimales.

`secuential` Algoritmo ingenuo $\mathcal{O}(n^3)$ con tres bucles anidados. Accede a $B[k][j]$, generando saltos de caché en la dimensión k.

`secuentialFlags` Mismo código fuente que `secuential`, compilado con `-O2` para medir el impacto de las optimizaciones automáticas del compilador (vectorización, reordenamiento de instrucciones, etc.).

`memory` Transpone la matriz B antes de multiplicar, de modo que el acceso interno es $B^T[j][k]$, convirtiendo todos los accesos en secuenciales en memoria.

`threads` Divide las filas de C equitativamente entre p hilos POSIX. Cada hilo calcula su bloque de filas de manera independiente sobre matrices compartidas.

`multiprocessing` Crea p procesos hijos con `fork()`. La matriz resultado C se ubica en memoria compartida anónima (`mmap`); las matrices A y B se heredan por *copy-on-write*. El tiempo se mide con `RUSAGE_SELF + RUSAGE_CHILDREN`.

El código fuente del proyecto se encuentra en: https://github.com/pausa11/HPC

3.3. Sistema de compilación (Makefile)

El proyecto utiliza un `Makefile` que compila los cinco binarios en el directorio `output/`:

```
make              # Compila los 5 binarios
make clean        # Elimina output/
```

Un aspecto clave del diseño es la estrategia deliberada de flags:

- `secuential` y `memory` compilan **sin ninguna bandera**, con el compilador en modo por defecto. Esto garantiza que los resultados reflejan el algoritmo puro, sin interferencia del optimizador.
- `secuentialFlags` compila el **mismo código fuente** que `secuential` pero con `-O2`, aislando el efecto de las optimizaciones automáticas del compilador.
- `threads` agrega únicamente `-pthread`, la bandera requerida por la librería POSIX de hilos.
- `multiprocessing` compila sin flags adicionales, ya que `fork()` y `mmap()` son llamadas al sistema estándar de POSIX.

Esta separación permite comparar el impacto de cada factor de forma independiente: algoritmo base, optimización de compilador, localidad de caché e hilos/procesos.

3.4. Sistema de benchmarking con checkpoints

Dado que las corridas completas pueden tardar varias horas (matrices de hasta 4000×4000 con 10 repeticiones), el script `scripts/RunAll.sh` implementa un sistema de **reanudación automática** basado en checkpoints.

Flujo de ejecución:

1. Al iniciar, el script busca en `stats/<hostname>/` si existe un directorio de corrida sin el sufijo `.done`. Si existe, lo reanuda; si no, crea uno nuevo con timestamp (`YYYYMMDD_HHMMSS`).
2. Cada medición exitosa registra una clave en `checkpoint.log` con el formato `<tipo>,<tamaño>,<config>,<run>` (ej. `threads,2000,n8,run3`).
3. La función `run_safe()` verifica antes de cada ejecución si esa clave ya existe en el log. De ser así, la omite (`[SKIP]`). Si el programa falla con código de error distinto de cero (por ejemplo, un `SIGSEGV` por falta de memoria en matrices muy grandes), registra el aviso pero continúa con la siguiente combinación sin abortar toda la corrida.
4. Al finalizar exitosamente, el directorio recibe el sufijo `.done`, impidiendo que futuras ejecuciones lo traten como corrida incompleta.

La estructura de salida resultante es la siguiente:

```
stats/<hostname>/<timestamp>.done/
  checkpoint.log        # 1210 entradas completadas
  secuential.csv        # 10 filas x 11 columnas
  secuential_flag.csv
  memory.csv
  threads2.csv  threads4.csv  threads8.csv  threads16.csv
  mutiprocessing2.csv  ...  mutiprocessing16.csv
```

Este diseño permitió recuperar corridas interrumpidas por suspensión del equipo o errores de memoria sin perder las mediciones ya realizadas.

3.5. Problema de medición: CPU acumulado vs. tiempo de pared

Durante el desarrollo se identificó un error crítico en la estrategia de medición de tiempo que distorsionaba completamente los resultados de los programas paralelos.

El problema original: la implementación inicial usaba `getrusage(RUSAGE_SELF)` con el campo `ru_utime` para medir el tiempo de usuario:

```
struct rusage start, end;
getrusage(RUSAGE_SELF, &start);
/* ... multiplicación ... */
getrusage(RUSAGE_SELF, &end);
double t = (end.ru_utime.tv_sec  - start.ru_utime.tv_sec) +
           (end.ru_utime.tv_usec - start.ru_utime.tv_usec) / 1e6;
```

El problema es que `RUSAGE_SELF` acumula el tiempo de CPU de **todos los hilos del proceso**. Con 8 hilos corriendo en paralelo durante 10 segundos reales cada uno, `ru_utime` reporta ≈80 segundos — más que el secuencial, que solo tiene un hilo. Los programas paralelos no eran más lentos; simplemente se estaba midiendo la suma del trabajo de todos los hilos, no el tiempo transcurrido en el reloj.

Para el multiprocesamiento el problema era análogo: con `RUSAGE_SELF + RUSAGE_CHILDREN` se sumaba el tiempo de CPU del proceso padre más el de cada proceso hijo, nuevamente acumulando en lugar de medir tiempo de pared.

La solución: migrar a `clock_gettime(CLOCK_MONOTONIC)`, que mide el tiempo real transcurrido (tiempo de pared) independientemente de cuántos hilos o procesos hayan estado activos:

```
struct timespec start, end;
clock_gettime(CLOCK_MONOTONIC, &start);
/* ... multiplicación ... */
clock_gettime(CLOCK_MONOTONIC, &end);
double elapsed = (end.tv_sec  - start.tv_sec) +
                 (end.tv_nsec - start.tv_nsec) / 1e9;
```

`CLOCK_MONOTONIC` garantiza además que el tiempo nunca retrocede (a diferencia de `gettimeofday`), lo que lo hace robusto frente a ajustes del reloj del sistema. Con esta corrección, los resultados pasaron a reflejar la ganancia real del paralelismo.

4. Pruebas

A continuación se presentan los tiempos promedio de ejecución (en segundos, sobre 10 repeticiones) para cada implementación y configuración, seguidos de las gráficas comparativas.

4.1. Secuencial

Secuencial											
Dimensiones	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.2424	1.7740	3.6358	6.8231	16.8662	21.8290	36.7362	60.7772	76.0408	224.9021	311.7885
2	0.2251	1.9065	3.8284	7.1391	17.4430	21.9414	37.9732	62.0054	76.4309	222.6342	303.6016
3	0.2188	1.8412	3.7366	6.9543	16.5286	21.5346	36.0005	59.6817	74.2137	220.6480	303.8271
4	0.2172	1.8337	3.7074	6.9244	16.6750	21.3882	35.7337	59.2924	73.9349	220.8070	303.6079
5	0.2174	1.8285	3.7029	6.9075	16.6371	21.3407	35.7943	59.1817	73.9824	221.0847	303.1106
6	0.2172	1.8444	3.7009	6.9154	16.6191	21.2897	35.7026	59.1398	73.7936	220.4881	305.9618
7	0.2162	1.8264	3.7050	6.9105	16.4523	21.5837	36.7144	59.3578	73.9886	220.5352	303.0252
8	0.2162	1.8275	3.7011	6.9049	16.7490	21.2863	35.7579	58.9758	73.9120	220.2637	303.1744
9	0.2171	1.8224	3.7057	6.9053	16.6755	21.2638	35.6191	59.1342	73.3610	220.6785	305.6457
10	0.2159	1.8229	3.6941	6.9012	16.6306	21.2257	35.7015	59.1027	73.6678	220.3174	303.3598
Pr	**0.2204**	**1.8328**	**3.7118**	**6.9286**	**16.6276**	**21.4683**	**36.1733**	**59.6649**	**74.3326**	**221.2359**	**304.7103**

Cuadro 1: Resultados de la ejecución secuencial.

4.2. Secuencial con flag

Secuencial Flag											
Dimensiones	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.1114	0.8064	1.4206	2.6020	9.4045	8.5509	18.9184	33.7694	30.1213	155.5912	215.0485
2	0.0783	0.8066	1.4298	2.6085	9.4383	8.4932	18.8105	33.7251	30.3186	155.5530	214.9413
3	0.0775	0.8070	1.4302	2.6095	9.5052	8.5155	18.2619	33.2180	29.7458	155.6369	215.0071
4	0.0779	0.8107	1.4252	2.6077	9.4858	8.5762	18.4624	33.9045	29.7730	155.6876	215.0617
5	0.0785	0.8093	1.4278	2.6031	9.3951	8.5296	18.9355	32.8358	30.3526	155.4830	215.0293
6	0.0780	0.8133	1.4262	2.6010	9.3411	8.5431	18.5397	33.4427	29.5868	155.5133	214.9728
7	0.0781	0.8155	1.4251	2.6023	9.4492	8.5613	18.3424	32.6311	29.9534	155.4831	215.0998
8	0.0790	0.8128	1.4275	2.6106	9.4580	8.4787	18.1945	32.9409	30.0746	155.6172	215.0716
9	0.0784	0.8089	1.4301	2.6043	9.3704	8.4737	18.1035	32.8535	29.6002	155.5337	214.9720
10	0.0785	0.8113	1.4288	2.6070	9.2772	8.4691	18.7310	33.7321	30.7115	155.6028	215.2506
Pr	**0.0816**	**0.8102**	**1.4271**	**2.6056**	**9.4125**	**8.5191**	**18.5300**	**33.3053**	**30.0238**	**155.5702**	**215.0455**
Speedup	**2.7014**	**2.2622**	**2.6004**	**2.6591**	**1.7665**	**2.5200**	**1.9521**	**1.7912**	**2.4758**	**1.4221**	**1.4169**

Cuadro 2: Resultados de la ejecución secuencial con flag.

4.3. Optimización de caché (Transpuesta)

Optimización de Caché (Transpuesta)											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.1810	1.1733	2.5524	4.7731	9.2692	14.0967	20.3470	31.2011	41.5041	53.7134	73.8984
2	0.1475	1.1682	2.5517	4.7637	9.2672	14.0901	20.3441	31.2104	41.5218	53.7355	73.9114
3	0.1482	1.1725	2.5512	4.7541	9.2733	14.0989	20.3473	31.2109	41.5054	53.7372	73.9751
4	0.1487	1.1697	2.5532	4.7467	9.2708	14.0860	20.3364	31.1988	41.5074	53.7343	73.8389
5	0.1486	1.1713	2.5527	4.7526	9.2842	14.0867	20.3523	31.1903	41.4999	53.7380	73.8257
6	0.1486	1.1721	2.5505	4.7474	9.2681	14.0817	20.3460	31.1913	41.5123	53.7250	73.8584
7	0.1472	1.1722	2.5481	4.7515	9.2658	14.0849	20.3414	31.1986	41.5045	53.7333	73.8572
8	0.1505	1.1709	2.5627	4.7532	9.2611	14.0947	20.3420	31.2029	41.5105	53.7346	73.8159
9	0.1482	1.1717	2.5540	4.7489	9.2702	14.0859	20.3440	31.2082	41.4796	53.7296	73.8231
10	0.1487	1.1685	2.5536	4.7504	9.2631	14.0816	20.3363	31.2011	41.4787	53.7746	73.8276
Pr	**0.1517**	**1.1710**	**2.5530**	**4.7542**	**9.2693**	**14.0887**	**20.3437**	**31.2014**	**41.5024**	**53.7355**	**73.8632**
Speedup	**1.4523**	**1.5652**	**1.4539**	**1.4574**	**1.7938**	**1.5237**	**1.7782**	**1.9122**	**1.7909**	**4.1170**	**4.1255**

Cuadro 3: Resultados de la ejecución con optimización de caché (transposición de B).

4.4. Multiprocesamiento — 2 Procesos

Multiprocesamiento 2 Procesos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.1429	0.9373	1.9557	4.0138	8.5986	12.9371	23.4569	37.9774	44.9045	113.5843	155.9533
2	0.1143	0.9384	1.9497	3.9549	8.6176	12.9108	23.1021	37.0049	44.3464	113.0938	155.2725
3	0.1149	0.9376	1.9864	4.0278	8.5981	12.8297	23.0653	37.0694	45.0395	113.4212	154.7572
4	0.1167	0.9364	1.9564	3.9401	8.5804	12.7792	22.9347	36.9075	44.3354	114.0897	154.7126
5	0.1130	0.9369	1.9834	4.0667	8.4859	12.6938	23.0471	37.2018	44.6837	112.8909	156.4468
6	0.1138	0.9341	1.9660	4.0226	8.5286	12.7535	22.8232	37.0604	44.7767	112.9346	155.8391
7	0.1130	0.9345	1.9821	4.0386	8.5395	12.7659	22.8817	37.2298	44.3559	113.7848	156.7856
8	0.1125	0.9378	1.9716	4.0740	8.5793	12.8104	22.9394	37.0883	43.8730	114.3844	156.6778
9	0.1197	0.9372	1.9998	3.9591	8.4135	12.8721	23.1572	37.3087	44.6027	112.7399	157.8157
10	0.1126	0.9326	1.9750	3.9368	8.4025	12.7816	22.9457	37.2539	44.2820	112.1757	155.7674
Pr	**0.1173**	**0.9363**	**1.9726**	**4.0035**	**8.5344**	**12.8134**	**23.0353**	**37.2102**	**44.5200**	**113.3099**	**156.0028**
Speedup	**1.8780**	**1.9576**	**1.8818**	**1.7308**	**1.9481**	**1.6755**	**1.5703**	**1.6034**	**1.6696**	**1.9524**	**1.9532**

Cuadro 4: Resultados de la ejecución con multiprocesamiento de 2 procesos.

4.5. Multiprocesamiento — 4 Procesos

Multiprocesamiento 4 Procesos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.0628	0.4826	1.0200	1.9060	4.5577	6.9276	16.5971	27.7566	24.4782	77.9001	109.2969
2	0.0603	0.4870	1.0067	1.8973	4.5821	6.8858	16.1001	27.7920	24.6311	77.8718	110.8876
3	0.0615	0.4921	1.0102	1.8924	4.5931	6.7783	16.3469	27.8234	24.3863	80.0305	109.0149
4	0.0608	0.4867	0.9881	1.9206	4.5718	6.3395	16.4075	27.3821	24.5415	80.1903	111.6487
5	0.0620	0.4840	0.9992	1.8874	4.5294	6.8448	16.5630	27.2921	24.4688	77.3804	111.3375
6	0.0601	0.4862	0.9965	1.9017	4.5768	6.9531	16.2526	27.4144	24.1561	79.7426	108.4640
7	0.0611	0.4828	0.9984	1.9097	4.6559	6.8605	15.8918	27.9737	24.5292	77.6989	107.7155
8	0.0593	0.4832	1.0035	1.8915	4.5336	6.7577	16.3921	27.8407	24.6638	77.9018	110.8594
9	0.0619	0.4835	0.9998	1.8792	4.4719	6.8315	16.2167	27.5950	24.5320	77.8102	111.6106
10	0.0603	0.4875	1.0055	1.9153	4.5988	6.8875	16.3580	26.7663	24.2713	79.7618	111.5128
Pr	**0.0610**	**0.4856**	**1.0028**	**1.9001**	**4.5671**	**6.8066**	**16.3126**	**27.5636**	**24.4658**	**78.6288**	**110.2348**
Speedup	**3.6118**	**3.7744**	**3.7014**	**3.6465**	**3.6406**	**3.1541**	**2.2176**	**2.1649**	**3.0382**	**2.8134**	**2.7641**

Cuadro 5: Resultados de la ejecución con multiprocesamiento de 4 procesos.

4.6. Multiprocesamiento — 8 Procesos

Multiprocesamiento 8 Procesos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.0549	0.3766	0.8910	1.6376	3.7895	5.5984	9.9653	16.5489	18.3811	55.9836	78.0496
2	0.0467	0.3661	0.8717	1.6303	3.6902	5.5854	10.2524	16.3267	18.4539	56.1620	74.0835
3	0.0472	0.3659	0.8669	1.6391	3.7119	5.5973	10.1399	16.1195	18.3224	55.9941	78.0254
4	0.0474	0.3674	0.8649	1.6219	3.6828	5.5986	9.9896	16.9615	18.2717	55.7331	74.2517
5	0.0472	0.3679	0.8721	1.6386	3.7197	5.5578	10.1953	16.9784	18.3799	56.1122	77.7920
6	0.0495	0.3672	0.8623	1.6400	3.7202	5.5789	10.0123	16.7057	18.1576	53.4435	74.4321
7	0.0477	0.3704	0.8726	1.6418	3.6988	5.6358	10.0221	16.7594	18.5298	53.5845	78.3446
8	0.0472	0.3660	0.8659	1.6302	3.6425	5.6332	10.2889	16.4102	18.4909	53.6404	78.0693
9	0.0490	0.3667	0.8674	1.6432	3.7007	5.6245	9.9976	16.6198	18.3964	55.9157	77.6011
10	0.0476	0.3699	0.8677	1.6394	3.6835	5.5691	9.8521	16.9265	18.3498	53.4549	77.8144
Pr	**0.0484**	**0.3684**	**0.8703**	**1.6362**	**3.7040**	**5.5979**	**10.0716**	**16.6357**	**18.3733**	**55.0024**	**76.8464**
Speedup	**4.5537**	**4.9754**	**4.2651**	**4.2346**	**4.4892**	**3.8350**	**3.5918**	**3.5869**	**4.0455**	**4.0224**	**3.9651**

Cuadro 6: Resultados de la ejecución con multiprocesamiento de 8 procesos.

4.7. Multiprocesamiento — 16 Procesos

Multiprocesamiento 16 Procesos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.0503	0.3668	0.8760	1.6357	3.5222	5.6300	9.9239	16.3558	19.2520	57.8405	81.0151
2	0.0488	0.3496	0.8633	1.6372	3.6314	5.6331	10.0311	16.4847	19.3700	57.7069	74.2280
3	0.0488	0.3628	0.8675	1.6222	3.6240	5.6727	9.8186	16.4386	18.9365	57.9585	74.2000
4	0.0477	0.3501	0.8575	1.6260	3.6179	5.7734	9.9010	16.7081	18.9564	57.9055	80.6712
5	0.0499	0.3567	0.8605	1.6303	3.6543	5.6252	9.8946	16.2126	18.8400	53.4439	80.9255
6	0.0497	0.3431	0.8627	1.6243	3.5315	5.6347	9.9530	16.5200	18.7527	53.5498	74.1465
7	0.0491	0.3518	0.8860	1.6263	3.5304	5.6652	9.8657	16.4069	18.8325	57.7699	80.8706
8	0.0446	0.3484	0.8640	1.6275	3.5837	5.6121	9.8626	16.6899	19.1566	53.5293	80.8009
9	0.0455	0.3451	0.8672	1.6259	3.6916	5.6330	10.0697	16.3585	19.2708	58.0269	74.1820
10	0.0462	0.3578	0.8693	1.6210	3.5811	5.6516	9.9337	16.3886	19.1688	53.5861	74.5170
Pr	**0.0481**	**0.3532**	**0.8674**	**1.6276**	**3.5968**	**5.6531**	**9.9254**	**16.4564**	**19.0536**	**56.1317**	**77.5557**
Speedup	**4.5822**	**5.1888**	**4.2788**	**4.2572**	**4.6228**	**3.7977**	**3.6444**	**3.6259**	**3.9016**	**3.9413**	**3.9288**

Cuadro 7: Resultados de la ejecución con multiprocesamiento de 16 procesos.

4.8. Hilos POSIX — 2 Hilos

Hilos POSIX — 2 Hilos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.1585	1.0467	2.3125	4.4521	9.5108	14.3277	25.6787	41.0976	50.4809	125.4056	173.0014
2	0.1356	1.0672	2.3566	4.4576	9.5778	14.2613	26.0394	41.1175	51.1017	125.0019	173.4423
3	0.1302	1.0713	2.3657	4.4230	9.6732	14.3871	25.9022	41.4932	50.7510	125.4363	172.0604
4	0.1304	1.0670	2.3743	4.4379	9.7277	14.5289	25.9027	41.5913	51.1354	124.7106	173.1689
5	0.1313	1.0716	2.3566	4.4529	9.6721	14.8376	25.8929	41.4118	51.1226	124.8950	175.0603
6	0.1330	1.0680	2.3656	4.4277	9.7212	14.7336	26.1578	41.5716	50.8867	125.0327	171.5349
7	0.1435	1.0691	2.3645	4.4633	9.5206	14.6598	26.1693	41.4899	50.7663	124.6779	173.7851
8	0.1403	1.0768	2.3635	4.4144	9.5698	14.5142	26.0777	41.3939	50.9926	125.1802	173.7498
9	0.1300	1.0684	2.3610	4.4572	9.7306	14.5497	25.9796	41.9432	51.1916	124.7894	171.0221
10	0.1395	1.0727	2.3649	4.4147	9.6082	14.7738	26.1910	42.3562	51.3235	125.3971	174.0787
Pr	**0.1372**	**1.0679**	**2.3585**	**4.4401**	**9.6312**	**14.5574**	**25.9991**	**41.5466**	**50.9752**	**125.0527**	**173.0904**
Speedup	**1.6061**	**1.7163**	**1.5738**	**1.5605**	**1.7264**	**1.4747**	**1.3914**	**1.4361**	**1.4582**	**1.7692**	**1.7605**

Cuadro 8: Resultados de la ejecución con 2 hilos POSIX (pthread).

4.9. Hilos POSIX — 4 Hilos

Hilos POSIX — 4 Hilos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.0703	0.5526	1.2178	2.2404	5.1057	8.0305	17.7012	27.5102	26.6623	80.7243	115.9338
2	0.0702	0.5598	1.2077	2.2489	5.1196	7.8173	18.0109	27.7699	26.6433	80.9598	114.0581
3	0.0708	0.5536	1.2092	2.2476	5.1608	8.0133	17.7117	27.6326	26.6152	83.0205	115.1659
4	0.0690	0.5536	1.2136	2.2531	5.1418	8.0435	17.7692	28.3576	26.5415	81.2420	112.2903
5	0.0720	0.5524	1.2121	2.2580	5.2125	8.0535	18.0199	27.7976	26.7625	80.4647	115.1236
6	0.0700	0.5500	1.2154	2.2514	5.2031	7.9404	17.8560	28.1445	26.6008	83.0187	112.6888
7	0.0751	0.5525	1.2101	2.2533	5.0779	8.0344	17.8495	28.1273	26.5698	83.2336	112.4521
8	0.0695	0.5522	1.2310	2.2518	5.1341	7.9472	17.9709	28.0883	26.6593	82.3411	111.7698
9	0.0761	0.5543	1.2216	2.2548	5.1755	7.9691	17.9720	27.9404	26.6689	81.6599	115.3545
10	0.0734	0.5488	1.2131	2.2525	5.3100	7.9056	17.0549	28.4616	26.8611	80.9965	114.7393
Pr	**0.0716**	**0.5530**	**1.2152**	**2.2512**	**5.1641**	**7.9755**	**17.7916**	**27.9830**	**26.6585**	**81.7661**	**113.9576**
Speedup	**3.0782**	**3.3144**	**3.0545**	**3.0778**	**3.2198**	**2.6920**	**2.0333**	**2.1322**	**2.7878**	**2.7052**	**2.6739**

Cuadro 9: Resultados de la ejecución con 4 hilos POSIX (pthread).

4.10. Hilos POSIX — 8 Hilos

Hilos POSIX — 8 Hilos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.0573	0.4218	1.0330	1.9726	4.1213	6.3187	10.8679	17.1915	20.7515	55.6723	82.7801
2	0.0536	0.4213	1.0403	1.9254	4.2799	6.3374	10.7572	17.4987	20.7460	55.7524	77.2184
3	0.0544	0.4230	1.0297	1.9128	4.1970	6.3521	10.8000	17.2395	20.8624	55.5634	82.8891
4	0.0531	0.4215	1.0332	1.9204	4.2882	6.2861	10.9216	17.6852	21.0830	55.5824	83.0148
5	0.0547	0.4188	1.0358	1.9152	4.1329	6.3347	10.8504	17.4252	21.0524	59.7375	77.1269
6	0.0538	0.4237	1.0347	1.9291	4.2493	6.3281	10.8027	17.3696	20.7369	55.5782	77.1369
7	0.0536	0.4227	1.0386	1.9090	4.2943	6.3875	10.7172	17.1802	20.6706	55.6648	77.4578
8	0.0546	0.4194	1.0520	1.9140	4.2078	6.3892	10.8096	17.4044	21.0706	59.5526	83.0382
9	0.0534	0.4231	1.0331	1.9179	4.1937	6.2961	10.9203	17.0399	20.8105	55.6902	77.3173
10	0.0545	0.4208	1.0398	1.9219	4.2585	6.3874	10.7730	17.6387	20.7884	59.5777	77.1781
Pr	**0.0543**	**0.4216**	**1.0370**	**1.9238**	**4.2223**	**6.3417**	**10.8220**	**17.3673**	**20.8572**	**56.8371**	**79.5158**
Speedup	**4.0589**	**4.3464**	**3.5793**	**3.6014**	**3.9378**	**3.3853**	**3.3425**	**3.4357**	**3.5638**	**3.8923**	**3.8321**

Cuadro 10: Resultados de la ejecución con 8 hilos POSIX (pthread).

4.11. Hilos POSIX — 16 Hilos

Hilos POSIX — 16 Hilos											
Dim	**500**	**1000**	**1300**	**1600**	**2000**	**2300**	**2600**	**3000**	**3300**	**3600**	**4000**
1	0.0525	0.3958	1.0368	1.9217	4.0339	6.4287	10.8811	17.6791	21.4173	54.5786	83.5712
2	0.0503	0.3975	1.0236	1.9008	4.1384	6.3875	10.7949	17.7655	21.2964	60.4073	75.5840
3	0.0530	0.4044	1.0128	1.9008	4.0749	6.4268	10.8171	17.4265	20.5444	60.3446	83.7214
4	0.0495	0.3924	1.0254	1.9042	4.1488	6.3846	10.6992	17.8138	21.5651	60.3970	83.6631
5	0.0516	0.3990	1.0159	1.9305	4.0776	6.3870	10.8827	17.7889	21.2278	54.6226	83.6623
6	0.0503	0.3976	1.0236	1.9063	4.0004	6.4359	10.7500	17.7789	21.3861	60.3667	83.7884
7	0.0512	0.3956	1.0316	1.9131	4.1356	6.4085	10.7597	17.6210	21.1517	54.6609	75.6386
8	0.0524	0.4005	1.0199	1.9381	4.0653	6.3862	10.8450	17.7816	20.9505	60.4155	75.5876
9	0.0490	0.3932	1.0157	1.9017	4.0454	6.4283	10.6521	17.9115	21.1348	60.4150	75.7416
10	0.0530	0.3963	1.0221	1.8891	4.1219	6.4126	10.9592	17.8338	21.1554	60.1099	83.3277
Pr	**0.0513**	**0.3972**	**1.0227**	**1.9106**	**4.0842**	**6.4086**	**10.8041**	**17.7401**	**21.1830**	**58.6318**	**80.4286**
Speedup	**4.2965**	**4.6139**	**3.6295**	**3.6264**	**4.0712**	**3.3498**	**3.3481**	**3.3638**	**3.5090**	**3.7735**	**3.7884**

Cuadro 11: Resultados de la ejecución con 16 hilos POSIX (pthread).

5. Gráficas comparativas

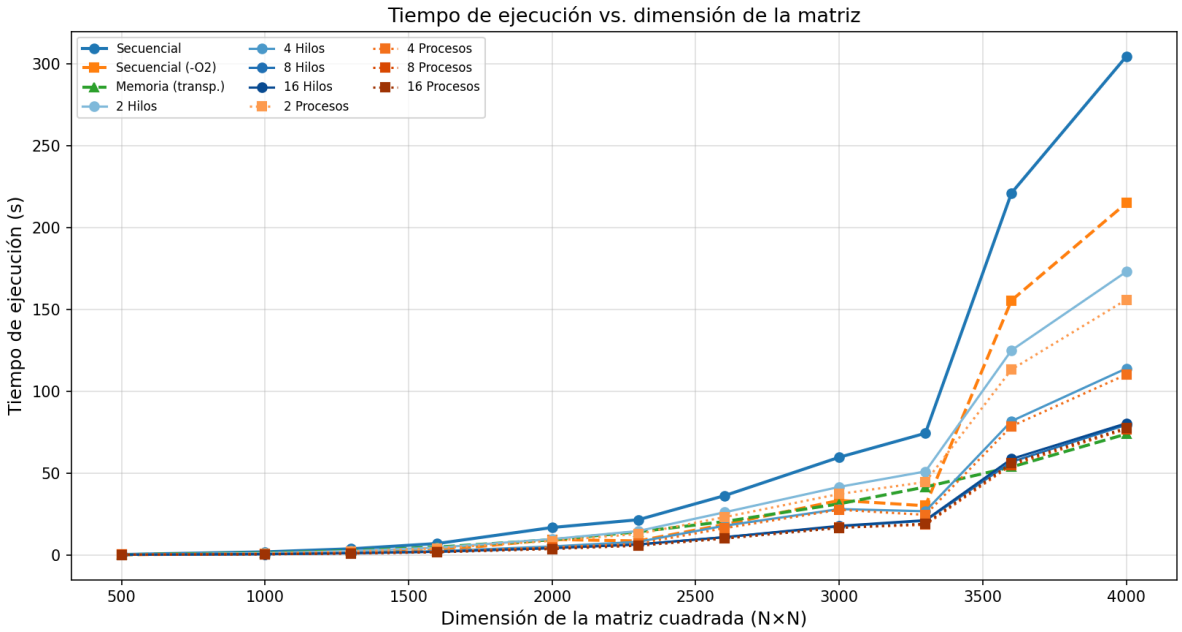

Figura 1: Tiempo de ejecución en función de la dimensión de la matriz — todas las variantes.

El crecimiento cúbico del algoritmo secuencial base es evidente; las versiones paralelas y optimizadas comprimen significativamente esta curva. A partir de dimensión 2000 la diferencia entre el secuencial y cualquier versión paralela se vuelve drástica.

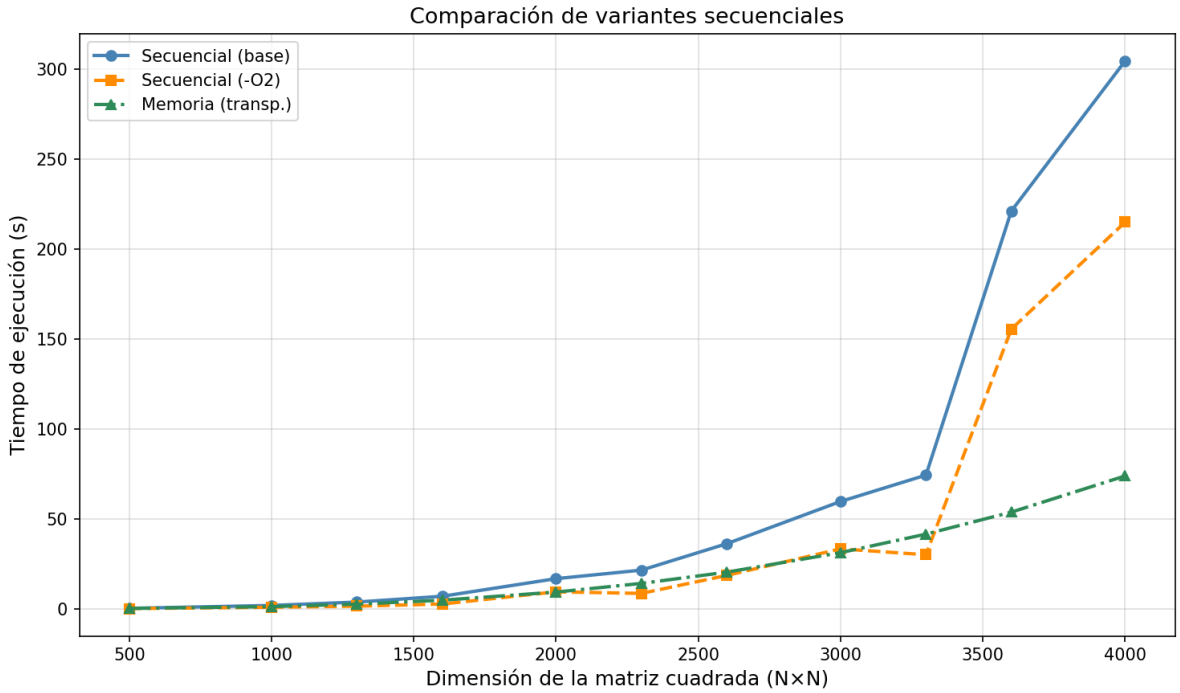

Figura 2: Comparación de variantes secuenciales: base, con `-O2` y con transposición de matriz.

Aislando las tres variantes secuenciales se aprecia con mayor claridad el impacto de cada optimización. La bandera `-O2` domina para matrices pequeñas, pero la versión con memoria transpuesta la supera a partir de dimensión ≈ 2300, cuando la penalización por fallos de caché del acceso columnar empieza a ser el cuello de botella.

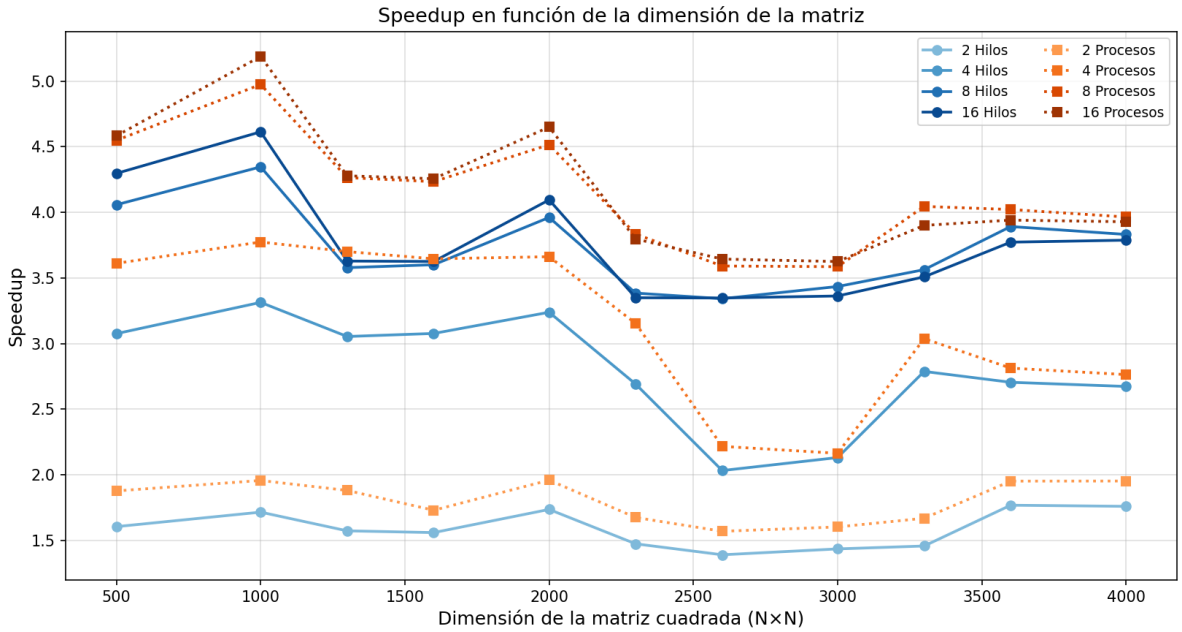

Figura 3: Speedup en función de la dimensión de la matriz.

El speedup de los métodos paralelos respecto al secuencial base muestra que el salto de 8 a 16 workers es notablemente menor que el de 4 a 8, evidenciando el límite impuesto por los núcleos de eficiencia (E-cores) del M4 que no aportan el mismo rendimiento que los P-cores en cargas de cómputo intensivo.

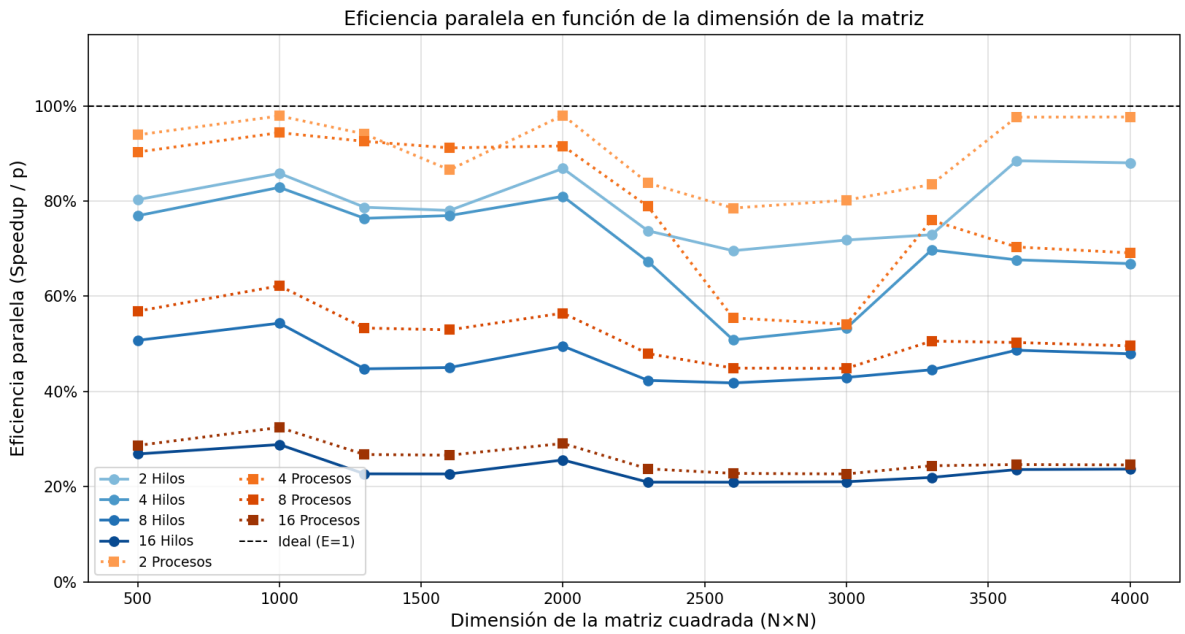

Figura 4: Eficiencia paralela $E = S_p/p$ en función de la dimensión de la matriz.

La eficiencia paralela ($E = S_p/p$) revela cuánto del speedup ideal se aprovecha realmente. Con 2 workers ronda el 80–90 %; con 16 cae al 25–32 %. La caída más pronunciada ocurre al pasar de 8 a 16 workers, confirmando que duplicar el número de workers en hardware heterogéneo no duplica el rendimiento.

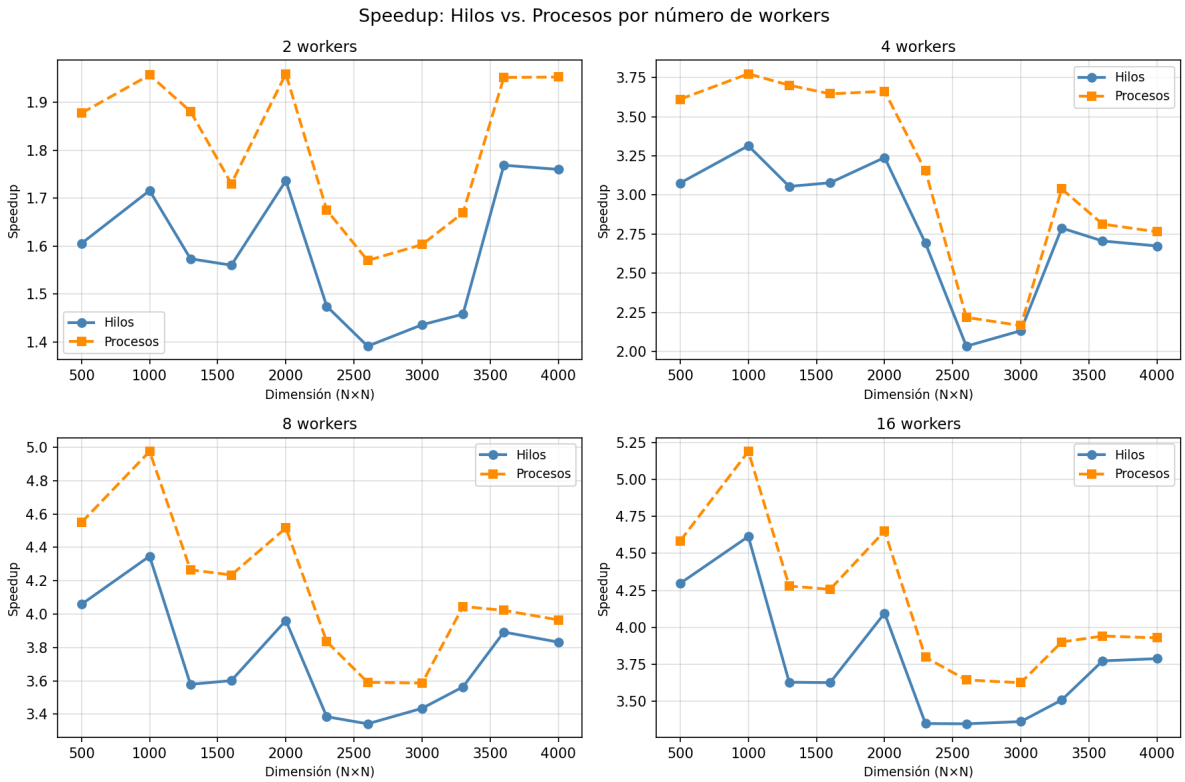

Figura 5: Speedup comparativo entre hilos y procesos para cada número de workers.

Comparando directamente hilos y procesos al mismo número de workers, para 2 y 4 los procesos muestran speedups ligeramente superiores; para 8 y 16 ambas estrategias convergen. El mecanismo de

`fork()` con `mmap` parece incurrir en menos overhead relativo que `pthread` para pocos workers, pero la diferencia es pequeña y se diluye con la carga de trabajo.

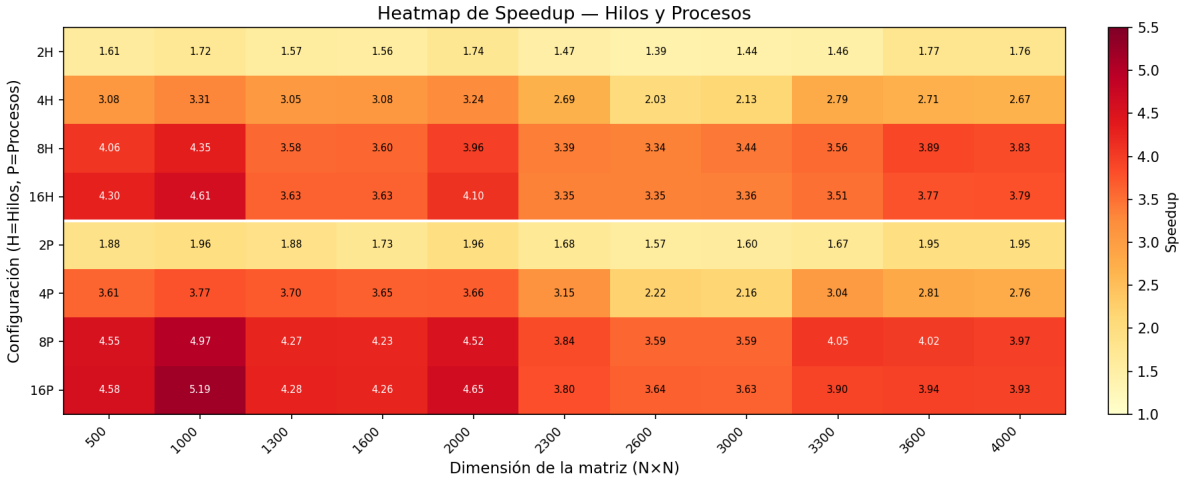

Figura 6: Heatmap de speedup: cada celda muestra S_p para una combinación de configuración y dimensión de matriz.

El heatmap resume de forma visual toda la información de configuración. La "zona óptima" (celdas más rojas) se concentra en la franja de 8–16 workers con matrices ≥ 1000. Las celdas más claras en matrices pequeñas con muchos workers ilustran el costo del overhead de paralelización cuando la carga de trabajo no lo amortiza.

6. Análisis de resultados

6.1. Impacto del compilador (`-O2`)

La bandera `-O2` produce un speedup de aproximadamente 2,5× para matrices pequeñas (500–1600), pero decrece hacia 1,4× para matrices de 4000. Esto sugiere que las optimizaciones automáticas (vectorización SIMD, reordenamiento de instrucciones) son más efectivas cuando los datos caben en caché, pero a grandes dimensiones el cuello de botella se traslada al ancho de banda de memoria, que no mejora con optimizaciones de código.

6.2. Optimización de caché (transpuesta)

La versión con transposición de B muestra un comportamiento diferente: para matrices pequeñas el speedup es modesto (1,4×–1,9×), pero a partir de dimensión 3600 supera los 4×. Esto es coherente con el fenómeno de *cache thrashing*: cuando la matriz supera el tamaño del caché L2/L3, los accesos columnares del algoritmo ingenuo generan un fallo de caché casi en cada operación, mientras que la versión transpuesta mantiene todos los accesos secuenciales.

6.3. Paralelismo con hilos

Con 2 hilos se obtiene un speedup consistente de $\approx$ 1,5×–1,8× (inferior al ideal de 2× por el overhead de `pthread_create` y `pthread_join`). Con 4 hilos el speedup alcanza $\approx$ 3,1×–3,4×; con 8 hilos sube a $\approx$ 3,5×–4,4×.

Significativamente, pasar de 8 a 16 hilos apenas mejora el speedup (de $\sim$ 3,9× a $\sim$ 4,3× en promedio). Esto es atribuible a la arquitectura heterogénea del M4: los 4 P-cores son mucho más rápidos que los 6 E-cores, de modo que al usar 16 hilos, los trabajadores asignados a E-cores terminan mucho más tarde, desbalanceando la carga y limitando la ganancia. El speedup máximo observado ($\approx$ 4,6×) es coherente con el número de P-cores disponibles.

6.4. Paralelismo con procesos

Los procesos con `fork` muestran speedups ligeramente superiores a los hilos en algunas configuraciones (especialmente con 8 y 16 trabajadores para matrices grandes). Dado que ambas implementaciones miden tiempo de pared con `clock_gettime(CLOCK_MONOTONIC)`, la diferencia refleja el overhead distinto de cada mecanismo: `fork()` con memoria compartida vía `mmap` incurre en mayor costo de creación pero elimina la contención de sincronización dentro del proceso, mientras que los hilos `pthread` comparten el espacio de memoria pero están sujetos a posible contención en el planificador. En cualquier caso, las diferencias son pequeñas y ambas estrategias convergen en eficiencia a medida que crece la dimensión de la matriz.

7. Conclusiones

1. **La optimización de caché rivaliza con el paralelismo para matrices grandes**: la transposición de B alcanza speedups superiores a $4\times$ para $N \geq 3600$, igualando configuraciones de 16 workers sin overhead de sincronización ni complejidad de código adicional. En cargas con restricciones de energía o simplicidad, esta estrategia es preferible al paralelismo explícito.

2. **La bandera `-O2` ofrece la mejor relación costo-beneficio para matrices pequeñas**: entrega speedups de $2{,}7\times$ para $N \leq 1600$ con cero cambios algorítmicos, superando incluso a 2 hilos ($\approx 1{,}6\times$). Su efectividad cae a $1{,}4\times$ en $N = 4000$, donde el cuello de botella se traslada al ancho de banda de memoria.

3. **El paralelismo solo compensa a partir de** $N \approx 1000$: por debajo de esta dimensión, el overhead de creación de hilos o procesos anula la ganancia. A partir de $N = 2000$, la brecha entre el secuencial (≈ 304 s en $N = 4000$) y cualquier versión paralela se vuelve irrecuperable.

4. **El punto óptimo de workers en el M4 es 8, no 16**: el salto de 4 a 8 workers aporta $\approx 1\times$ de speedup adicional, mientras que el de 8 a 16 apenas suma $0{,}3\times$. La arquitectura heterogénea del chip (4 P-cores + 6 E-cores) genera desbalance de carga al usar 16 workers, limitando la ganancia real al equivalente de los P-cores disponibles.

5. **La eficiencia paralela se degrada al escalar workers**: cae de $\approx 85\,\%$ con 2 workers a $\approx 28\,\%$ con 16, evidenciando que maximizar el número de workers no equivale a maximizar el rendimiento en hardware heterogéneo.

6. **Hilos y procesos son equivalentes en rendimiento**: las diferencias de speedup entre `pthread` y `fork` + `mmap` son menores a $0{,}5\times$ y desaparecen al crecer la dimensión de la matriz. La elección entre ambos debe basarse en criterios de diseño del sistema, no de rendimiento puro.

8. Bibliografía

Referencias

[1] Cortéz, A. (2004). Teoría de la complejidad computacional y teoría de la información. *Revista de Investigación de Sistemas e Informática*, 1(1), 102–105. https://revistasinvestigacion.unmsm.edu.pe/index.php/sistem/article/view/3216

[2] Ferestrepoca. (2019). Paradigmas de programación paralela. http://ferestrepoca.github.io/paradigmas-de-programacion/paralela/paralela_teoria/index.html

[3] López, A. (2017). Introducción al High Performance Computing. *Encamina Blog*. https://blogs.encamina.com/por-una-nube-sostenible/introduccion-al-high-performance-computing/

[4] Montero, L. H., & Antunez, R. R. (2011). Parallel programming: definitions, mechanisms and trouble. https://www.researchgate.net/publication/274960405

[5] Qaz Wiki. (2020). Algoritmos de multiplicación de matrices. https://es.qaz.wiki/wiki/Matrix_multiplication_algorithm

[6] Apple Inc. (2024). Apple M4 chip. https://www.apple.com/mac-mini/

[7] Amdahl, G. M. (1967). Validity of the single processor approach to achieving large scale computing capabilities. *Proceedings of AFIPS Spring Joint Computer Conference*, pp. 483–485.